

# Lab 1 Report

## Basic Image Classification

Due Date: September 18, 2020

<https://github.com/michaeldlee23/cs390-lab1>

### Resources used

- Explanation of calculus  
<https://www.youtube.com/watch?v=GlcnxUlrtek&t=390s>
- Starting point for determining number of hidden neurons to use  
<https://stats.stackexchange.com/a/136542>
- Tensorflow and Keras model creation, training, predicting, optimizing  
[https://www.tensorflow.org/api\\_docs/python/tf/keras/](https://www.tensorflow.org/api_docs/python/tf/keras/)

### Completed portions of lab

1. [30] Custom Neural Net
  - ✓[5] Sigmoid and sigmoid derivative functions
  - ✓[10] Train Function (using backpropagation properly)
  - ✓[15] Fully functioning 2-layer neural net
  - ✓[+3] EC: implement an option to make the network 3 layer
  - ✓[+5] EC: make the network N layer, where N is given in the constructor
  - ✓?[+1] EC: implement a second activation function (ReLU) that your network can use. The activation should be specified in the constructor
2. [30] TF Neural Net
  - ✓[30] Implement a function that builds a 2 layer neural net using either Tensorflow or Keras.
  - [+6] EC: Get accuracy to 99%.
3. [20] Pipeline & Misc.
  - ✓[5] Preprocess data such that values are between 0.0 and 1.0
  - ✓[15] Create an F1 score confusion matrix in the evaluation function and print it
  - ✓[+5] EC: Look up and learn about the iris dataset. Download the dataset and write a program to classify it using your custom neural net.
4. ✓[20] Report

## Summary

- Custom Neural Network

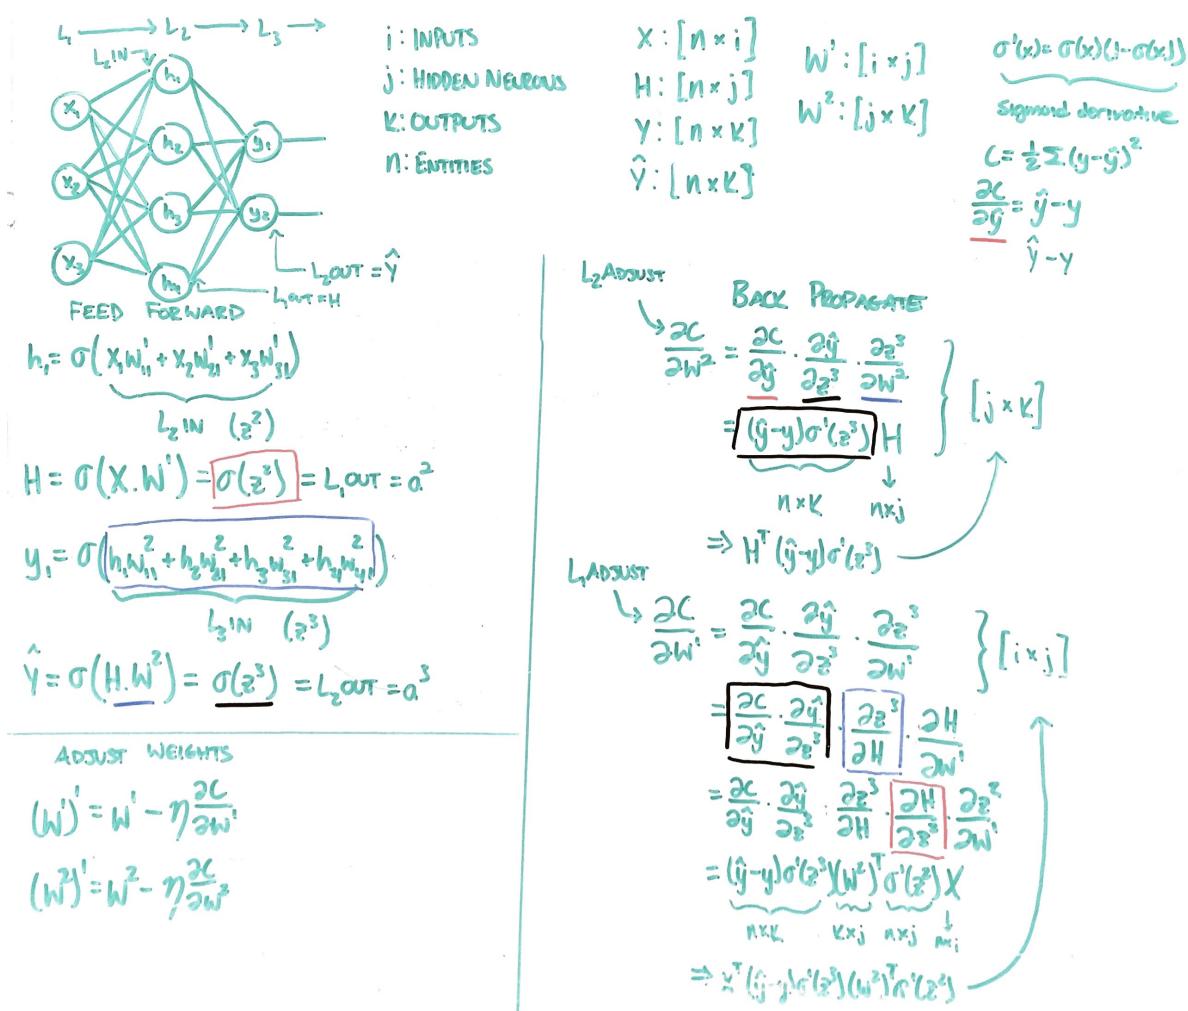


Figure 1: Work through backpropagation calculus

In order to understand how to implement the backpropagation algorithm, I needed to fully understand the math behind the process. I heavily relied on my whiteboarded work and constantly referenced it while I implemented the custom neural net, as it proved to be extremely helpful in keeping track of the dimensions of inputs. It also helped me keep track of variable names, as there were so many different values and matrices to keep track of.

In order to make testing easier, I implemented command line arguments to adjust hyperparameters:

Usage:

```
-a [algorithm | guesser, custom_net, tf_net]
-e [number of epochs]
-b [batch size]
-n [number of hidden neurons]
-l [initial learning rate]
-f [activation function | sigmoid, relu]
```

- Tensorflow Neural Network

The TensorFlow network was implemented in a similar manner that was shown on the lecture slides. Playing around with the hyperparameters (number of epochs and number of hidden neurons), we can see that the TensorFlow network performs significantly better than the custom net, as expected. In attempts to achieve 99% accuracy, I added layers, increased the number of hidden neurons, and tried different optimizers and batch sizes. Accuracy persistently hovered at around 98.2%.

# Relevant outputs

## 1. F1 Confusion Matrix

```
HYPERPARAMETERS:
net: custom_net epochs: 500    batchSize: 100  neuronsPerLayer: 5    learningRate: 0.1

Classifier algorithm: custom_net
Classifier accuracy: 57.640000%
Classifier confusion matrix:
[[ 931.    2.    73.    73.    7.    646.    12.    770.    736.    40.    3290.]
 [    0.  1086.    22.    23.    3.    7.    1.    17.    12.    1.    1172.]
 [   17.    20.   882.    23.    3.    22.   41.    30.   43.    2.   1083.]
 [    2.    15.    7.    853.    4.    66.    0.    23.   37.   14.   1021.]
 [    7.    2.    11.    3.    892.   26.   30.   26.   21.   772.   1790.]
 [    2.    1.    2.    11.    0.   29.    0.    2.    5.    2.    54.]
 [    3.    6.   25.    0.   26.    6.   844.    2.   14.    5.   931.]
 [    9.    2.    0.   13.   11.   56.   17.   86.   60.   31.   285.]
 [    2.    1.    8.    8.    0.   10.    0.   14.   19.    0.    62.]
 [    7.    0.    2.    3.   36.   24.   13.   58.   27.   142.   312.]
 [ 980.  1135.  1032.  1010.   982.   892.   958.  1028.   974.  1009.  10000.]]

Classifier F1 score matrix:
[[0.4361 nan nan nan nan nan nan nan nan nan]
 [ nan 0.9415 nan nan nan nan nan nan nan nan]
 [ nan nan 0.834 nan nan nan nan nan nan nan]
 [ nan nan nan 0.84 nan nan nan nan nan nan nan]
 [ nan nan nan nan 0.6436 nan nan nan nan nan]
 [ nan nan nan nan nan 0.0613 nan nan nan nan]
 [ nan nan nan nan nan nan 0.8936 nan nan nan]
 [ nan nan nan nan nan nan nan 0.131 nan nan]
 [ nan nan nan nan nan nan nan nan 0.0367 nan]
 [ nan nan nan nan nan nan nan nan nan 0.215 ]]
```

Epochs: 500, Neurons/Layer: 5

```
HYPERPARAMETERS:
net: custom_net epochs: 500    batchSize: 100  neuronsPerLayer: 10   learningRate: 0.1

Classifier algorithm: custom_net
Classifier accuracy: 90.100000%
Classifier confusion matrix:
[[ 909.    0.    8.    20.    0.    24.    8.    1.    4.    6.    980.]
 [    0.  1100.    2.    0.    0.    4.    3.   11.    4.    4.   1128.]
 [    7.    9.   927.   21.    5.    8.   10.   28.    8.    1.   1024.]
 [   11.    0.   27.   871.    0.   38.    9.    7.   21.   21.   1005.]
 [    1.    1.    9.    3.   915.    5.    9.   17.    8.   34.   1002.]
 [   31.    1.    1.   26.    4.   730.   14.    0.   50.    7.    864.]
 [   14.    5.   17.    7.   23.   29.   898.    3.   15.    3.   1014.]
 [    5.    2.   15.   13.    1.    5.    1.   920.    4.   19.    985.]
 [    1.   16.   22.   43.    4.   37.    6.    4.   847.   21.   1001.]
 [    1.    1.    4.    6.   30.   12.    0.   37.   13.   893.   997.]
 [ 980.  1135.  1032.  1010.   982.   892.   958.  1028.   974.  1009.  10000.]]

Classifier F1 score matrix:
[[0.9276 nan nan nan nan nan nan nan nan nan]
 [ nan 0.9722 nan nan nan nan nan nan nan nan]
 [ nan nan 0.9018 nan nan nan nan nan nan nan]
 [ nan nan nan 0.8645 nan nan nan nan nan nan]
 [ nan nan nan nan 0.9224 nan nan nan nan nan]
 [ nan nan nan nan nan 0.8314 nan nan nan nan]
 [ nan nan nan nan nan nan 0.9108 nan nan nan]
 [ nan nan nan nan nan nan nan 0.9141 nan nan]
 [ nan nan nan nan nan nan nan nan 0.8577 nan]
 [ nan nan nan nan nan nan nan nan nan 0.8903]]
```

Epochs: 500, Neurons/Layer: 10

```
HYPERPARAMETERS:
net: custom_net epochs: 500    batchSize: 100  neuronsPerLayer: 20   learningRate: 0.1

Classifier algorithm: custom_net
Classifier accuracy: 92.120000%
Classifier confusion matrix:
[[ 952.    0.    6.    2.    2.    11.   13.    1.    3.    9.    999.]
 [    0.  1115.    1.    1.    2.    3.    3.   11.    5.    4.   1145.]
 [    3.    0.   923.   27.    7.    4.    9.   22.    8.    1.   1004.]
 [    0.    7.   14.   914.    0.   32.    1.   13.   31.   21.   1033.]
 [    1.    0.   12.    0.   922.    5.    9.   12.   38.   1004.]
 [    4.    0.    8.   29.    3.   786.   18.    0.   21.    8.    877.]
 [   12.    3.   18.    5.    9.   17.   899.    3.   12.    1.    979.]
 [    3.    1.   13.   14.    1.   12.    1.   949.   10.   24.   1028.]
 [    5.    9.   31.   13.    4.   19.    5.    3.   861.   12.    962.]
 [    0.    0.    6.    5.   32.    3.    0.   21.   11.   891.    969.]
 [ 980.  1135.  1032.  1010.   982.   892.   958.  1028.   974.  1009.  10000.]]

Classifier F1 score matrix:
[[0.9621 nan nan nan nan nan nan nan nan nan]
 [ nan 0.9781 nan nan nan nan nan nan nan nan]
 [ nan nan 0.9067 nan nan nan nan nan nan nan]
 [ nan nan nan 0.8948 nan nan nan nan nan nan]
 [ nan nan nan nan 0.9285 nan nan nan nan nan]
 [ nan nan nan nan nan 0.8886 nan nan nan nan]
 [ nan nan nan nan nan nan 0.9282 nan nan nan]
 [ nan nan nan nan nan nan nan 0.9232 nan nan]
 [ nan nan nan nan nan nan nan nan 0.8895 nan]
 [ nan nan nan nan nan nan nan nan nan 0.9009]]
```

Epochs: 500, Neurons/Layer: 20


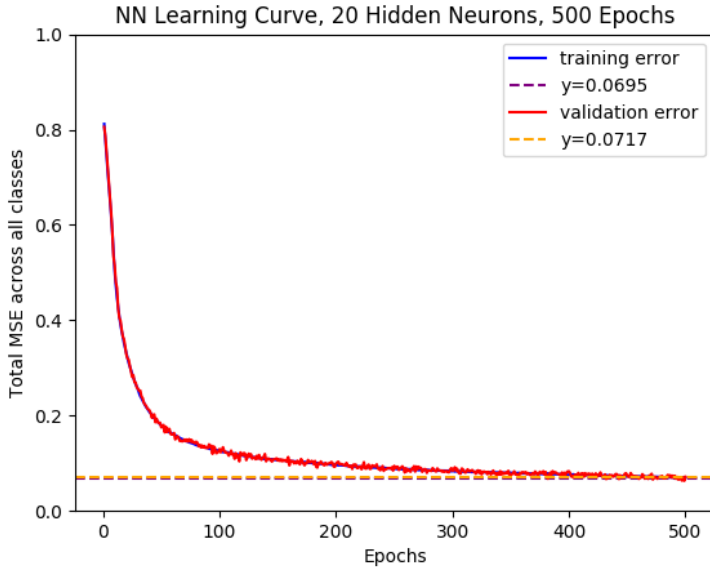


```
HYPERPARAMETERS:
net: custom_net epochs: 1000   batchSize: 100  neuronsPerLayer: 20   learningRate: 0.1

Classifier algorithm: custom_net
Classifier accuracy: 93.140000%
Classifier confusion matrix:
[[ 951.    0.   10.    2.    2.    7.   15.    2.    3.    9.   1001.]
 [    0.  1119.    5.    2.    0.    3.    3.    8.    4.    7.   1151.]
 [    3.    1.   936.   28.    7.    3.    6.   21.    8.    0.   1013.]
 [    0.    6.   12.   921.    0.   28.    1.   10.   22.   19.   1019.]
 [    2.    0.   10.    1.   921.    2.    6.    3.   10.   34.    989.]
 [    3.    0.    6.   20.    2.   804.   14.    0.   14.    7.    870.]
 [   12.    2.   14.    6.   13.   16.   906.    2.   10.    2.    983.]
 [    3.    1.   12.   13.    2.    6.    2.   966.    8.   19.   1032.]
 [    5.    6.   22.   14.    3.   20.    5.    2.   889.   11.    977.]
 [    1.    0.    5.    3.   32.    3.    0.   14.    6.   901.    965.]
 [ 980.  1135.  1032.  1010.   982.   892.   958.  1028.   974.  1009.  10000.]]

Classifier F1 score matrix:
[[0.9601 nan nan nan nan nan nan nan nan nan]
 [ nan 0.979 nan nan nan nan nan nan nan nan]
 [ nan nan 0.9154 nan nan nan nan nan nan nan]
 [ nan nan nan 0.9078 nan nan nan nan nan nan]
 [ nan nan nan nan 0.9346 nan nan nan nan nan]
 [ nan nan nan nan nan 0.9126 nan nan nan nan]
 [ nan nan nan nan nan nan 0.9335 nan nan nan]
 [ nan nan nan nan nan nan nan 0.9379 nan nan]
 [ nan nan nan nan nan nan nan nan 0.9113 nan]
 [ nan nan nan nan nan nan nan nan nan 0.9129]]
```

Epochs: 1000, Neurons/Layer: 20

## 2. Error Plots



To evaluate my model's learning curve, I used cross validation with a 90-10 split. At the beginning of each epoch, I randomly shuffle the inputted data sets and partition 10% to be used for validation, while the rest is then used to train the model. At the end of the epoch, I run the model against the training and validation set and calculate the total mean square error across all output classes. As we can see from the outputted graphs, the model appears to not overfit at all, as the training and validation error over time remains practically identical.

To observe the effects of certain hyperparameters (namely epoch number and hidden

layer size), I tested the network under several different cases. We can see that increasing the hidden layer size drastically increases accuracy from 5 to 10, but its effects diminish as we go from 10 to 20.

### 3. TensorFlow Output

```

HYPERPARAMETERS:
net: tf_net      epochs: 50      batchSize: 100  neuronsPerLayer: 512  learningRate: 0.1

Classifier algorithm: tf_net
Classifier accuracy: 98.210000%
Classifier confusion matrix:
[[ 970.    1.    2.    0.    1.    4.    3.    0.    2.    1.  984.]
 [   0.  1126.    2.    0.    1.    0.    2.    3.    0.    3. 1137.]
 [   3.    1.  1016.    8.    3.    0.    1.    6.    4.    1. 1043.]
 [   0.    1.    0.  987.    1.    8.    1.    1.    2.    5. 1006.]
 [   0.    0.    1.    0.  961.    1.    1.    0.    1.    6.  971.]
 [   0.    1.    0.    5.    0.  870.    3.    1.    1.    5.  886.]
 [   4.    2.    2.    0.    4.    4.  946.    0.    1.    1.  964.]
 [   1.    1.    4.    2.    2.    0.    0.  1010.    5.    4. 1029.]
 [   2.    2.    5.    4.    0.    3.    1.    4.  956.    4.  981.]
 [   0.    0.    0.    4.    9.    2.    0.    3.    2.  979.  999.]
 [  980.  1135.  1032. 1010.  982.  892.  958. 1028.  974. 1009. 10000.]]

Classifier F1 score matrix:
[[0.9878   nan    nan    nan    nan    nan    nan    nan    nan    nan]
 [   nan  0.9912   nan    nan    nan    nan    nan    nan    nan    nan]
 [   nan    nan  0.9793   nan    nan    nan    nan    nan    nan    nan]
 [   nan    nan    nan  0.9792   nan    nan    nan    nan    nan    nan]
 [   nan    nan    nan    nan  0.9841   nan    nan    nan    nan    nan]
 [   nan    nan    nan    nan    nan  0.9786   nan    nan    nan    nan]
 [   nan    nan    nan    nan    nan    nan  0.9844   nan    nan    nan]
 [   nan    nan    nan    nan    nan    nan    nan  0.982   nan    nan]
 [   nan    nan    nan    nan    nan    nan    nan    nan  0.978   nan]
 [   nan    nan    nan    nan    nan    nan    nan    nan    nan  0.9751]]

```

Epochs: 50, Neurons/Layer: 512



#### 4. Extra Content

- N-Layer Custom Net

I implemented an N-Layer custom net in `extra.py`. I also implemented command-line argument parsing to easily set hyperparameters; using the `-l` flag will set the number of hidden layers. Below is the output for a network with 3 hidden layers, each layer having 10 neurons, trained over 500 epochs.

```
HYPERPARAMETERS:
net: custom_net epochs: 500    batchSize: 100  hiddenSize: 10  hiddenLayers: 3 activation: sigmoid

Classifier algorithm: custom_net
Classifier accuracy: 88.470000%
Classifier confusion matrix:
[[ 922.    0.   16.   18.    0.   11.   15.    9.    3.    6. 1000.]
 [    0. 1095.   21.    5.    2.    2.    2.   16.    9.    1. 1153.]
 [    9.    9.  877.   29.    2.   11.   14.   39.   20.    4. 1014.]
 [    4.    5.   21.  858.    0.   55.    1.   11.   12.   12.  979.]
 [    7.    0.    7.    1.  881.   11.   20.    9.    7.   57. 1000.]
 [    7.    3.   10.   55.    1.  731.    7.    2.   68.   17.  901.]
 [   17.    5.   23.    3.   24.   17.  891.    0.   12.    0.  992.]
 [    9.    3.   10.    8.    5.   11.    2.  898.   12.   16.  974.]
 [    5.   14.   41.   24.   15.   37.    6.   13.  814.   16.  985.]
 [    0.    1.    6.    9.   52.    6.    0.   31.   17.  880. 1002.]
 [  980. 1135. 1032. 1010.  982.  892.  958. 1028.  974. 1009. 10000.]]

Classifier F1 score matrix:
[[0.9313    nan    nan    nan    nan    nan    nan    nan    nan    nan]
 [    nan 0.9572    nan    nan    nan    nan    nan    nan    nan    nan]
 [    nan    nan 0.8573    nan    nan    nan    nan    nan    nan    nan]
 [    nan    nan    nan 0.8627    nan    nan    nan    nan    nan    nan]
 [    nan    nan    nan    nan 0.889    nan    nan    nan    nan    nan]
 [    nan    nan    nan    nan    nan 0.8154    nan    nan    nan    nan]
 [    nan    nan    nan    nan    nan    nan 0.9138    nan    nan    nan]
 [    nan    nan    nan    nan    nan    nan    nan 0.8971    nan    nan]
 [    nan    nan    nan    nan    nan    nan    nan    nan 0.831    nan]
 [    nan    nan    nan    nan    nan    nan    nan    nan    nan 0.8752]]
```

Epochs: 500, Neurons/Layer: 10, Hidden Layers: 3

- ReLU Activation

I attempted to implement the option to use a ReLU activation function instead of sigmoid, however there are some unexpected results. I have implemented the `_relu()` and `_reluDerivative()` functions that appear to behave as intended, but when actually running the model using these activation functions we get very poor accuracy — the model tends to only pick 0s and 1s. I tried using a smaller learning rate (0.001 instead of 0.1) which had minimal improvement. I also tried using ReLU on just the hidden layer, and kept the output layer as sigmoid, but that also had minimal improvement.

- Iris Dataset

The option to run the neural net on the iris dataset was implemented in `extra.py`, which can be specified using the `-d iris` flag. Here are the results of running the

custom net on the iris dataset with 1 hidden layer, 20 hidden neurons, and 1000 epochs:

```
HYPERPARAMETERS:
net: custom_net epochs: 1000    batchSize: 100  hiddenSize: 20  hiddenLayers: 1

Classifier algorithm: custom_net
Classifier accuracy: 93.333333%
Classifier confusion matrix:
[[15.  0.  0. 15.]
 [ 0. 13.  2. 15.]
 [ 0.  1. 14. 15.]
 [15. 14. 16. 45.]]

Classifier F1 score matrix:
[[1.      nan    nan]
 [  nan 0.8966  nan]
 [  nan    nan 0.9032]]
```

Epochs: 1000, Neurons/Layer: 20, Hidden Layers: 1

The iris dataset was obtained through python's `sklearn.datasets` package, and contains 150 training samples. Since no test set is provided, I had to shuffle the given data and arbitrarily took 45 samples to set aside as the test set. The remaining 105 sample were used to train the model.